

深圳大学学报(理工版)

Journal of Shenzhen University(Science and Engineering)

ISSN 1000-2618,CN 44-1401/N

《深圳大学学报(理工版)》网络首发论文

题目: 基于全局鲁棒 Retinex 模型的多通道弱光图像增强算法
作者: 吴翰宁, 易积政, 李潇瑶, 李思佳
收稿日期: 2024-07-10
网络首发日期: 2025-01-23
引用格式: 吴翰宁, 易积政, 李潇瑶, 李思佳. 基于全局鲁棒 Retinex 模型的多通道弱光图像增强算法[J/OL]. 深圳大学学报(理工版).
<https://link.cnki.net/urlid/44.1401.N.20250122.1116.004>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

【电子与信息科学 / Electronic and Information Science】

基于全局鲁棒 Retinex 模型的多通道弱光图像增强算法

吴翰宁¹, 易积政², 李潇瑶², 李思佳²

1) 中南林业科技大学电子信息与物理学院, 湖南长沙 410004; 2) 中南林业科技大学前沿交叉学科学院, 湖南长沙 410004

摘要: 针对现有增强光照方法忽略不同光照下色相和饱和度的变化, 且在抑制噪声的同时丢失过多细节信息的问题, 基于 Retinex 理论提出一种在所有色彩通道上增强光照的全局鲁棒 Retinex 模型(global robust Retinex model, GRM). 采用收缩映射实现分数阶范数, 使分解出的照明图更平滑; 针对反射图梯度, 采取基于输入图像信息计算得到的权重矩阵和正则项来获取噪声少、细节多的反射图; 选择交替方向乘法对模型进行求解, 并通过伽玛校正获取理想照明图; 将处理后的反射图与照明图合并得到最终结果. 在 Adobe FiveK、DICM、VV 和 LIME 数据集上的实验结果表明, GRM 不仅在峰值信噪比、结构相似度、图像质量评估指标等方面可以与鲁棒 Retinex 模型、低秩正则化 Retinex 模型和即插即用 Retinex 模型等方法相媲美, 而且降噪能力更强以及图像光照恢复更明显.

关键词: 计算机图像; 弱光图像增强; Retinex 模型; 交替方向乘法; 分数阶范数; 图像降噪

中图分类号: TP37

文献标志码: A

DOI:

Multi-channel low-light image enhancement method based on global robust Retinex model

WU Hanning¹, YI Jizheng², LI Xiaoyao², and LI Sijia²

1) College of Electronic Information and Physics, Central South University of Forestry and Technology, Changsha 410004, P. R. China

2) College of Advanced Interdisciplinary Studies, Central South University of Forestry Technology, Changsha 410004, P. R. China

Abstract: To address the issue that existing illumination enhancement methods overlook the changes in hue and saturation under different lighting conditions, and that they lose too much detail information while suppressing noise, a global robust Retinex model (GRM) is proposed based on the Retinex theory to enhance illumination across all color channels. A contraction mapping is used to implement fractional-order norms, making the decomposed illumination map smoother. For the reflection map gradient, a weight matrix and regularization term calculated based on the input image information are employed to obtain a reflection map with less noise and more details. The alternating direction method of multipliers is chosen to solve the model, and gamma correction is applied to obtain the ideal illumination map. The processed reflection map is then combined with the illumination map to produce the final result. Experimental results on the Adobe FiveK, DICM, VV, and LIME datasets show that GRM not only competes with methods such as the robust Retinex model, low-rank regularization Retinex model, and plug-and-play Retinex model in terms of peak signal-to-noise ratio, structural similarity, and image quality assessment metrics, but also exhibits stronger denoising capabilities and more noticeable image illumination recovery.

Key words: computer visual; low-light image enhancement; Retinex model; alternating direction method of multipliers; fractional norm; image denoising

Received: 2024-07-10; **Accepted:** 2024-11-27;

Foundation: Hunan Provincial Graduate Research Innovation Project (CX20240692); Graduate Research Innovation Fund Project of Central South University of Forestry and Technology (2023CX02091)

Corresponding author: Professor YI Jizheng (E-mail: T20152279@csuft.edu.cn)

Citation: WU Hanning, YI Jizheng, LI Xiaoyao, et al. Multi-channel low-light image enhancement method based on global robust Retinex model [J]. Journal of Shenzhen University Science and Engineering, XXXX, XX(XX): 1-8. (in Chinese)

环境光照条件不佳时拍摄图像常会出现能见度低、对比度低和噪声严重等现象,因此,弱光图像增强算法被广泛用于补偿拍摄到影像的光照,并使得边缘和细节更清晰.在计算机视觉发展早期,有学者提出几类弱光图像增强算法:基于直方图均衡的方法^[1],此方法常存在照明不均匀或增强不适当问题;去雾算法,DONG等^[2]指出反转的弱光图像与含雾的图像相似;曝光融合算法,此方法可以准确增强对比度和亮度^[3].

近期基于学习的方法得到了很多关注.赵明华等^[4]在增强弱光图像的U-Net网络中引入了注意力机制.WANG等^[5]采用了Retinex理论的概念设计网络结构.CAI等^[6]将变换器(Transformer)引入弱光图像领域.陈彬等^[7]结合了Transformer和卷积神经网络各自的优势.但是,这些方法通常需要大量训练数据,当测试图像与训练数据集相比差异较大时,结果可能有明显伪影.

LAND^[8]提出的Retinex理论对人类视觉系统如何捕捉光和颜色进行了建模.JOBSON等^[9]提出了多尺度Retinex模型,将分解出的反射图作为结果,但不考虑照明图会不自然或过度增强.WANG等^[10]提出自然度保持弱光图像增强算法,既能增强细节又能保持图像自然度.基于全变分的方法在计算机视觉领域得到了广泛应用,如李潇瑶等^[11]将全变分用于图像去噪.许多基于Retinex模型的方法^[12-16]在分解照明图和反射图的过程也应用了全变分,增强了显示效果.

近年来出现了一些考虑噪声抑制的基于Retinex模型的弱光增强算法.LI等^[17]首次尝试在Retinex模型中估计噪声图并且弃用对数变换.REN等^[18]引入低秩正则化,并且在处理图像的全过程中抑制了噪声.LIN等^[19]在对照明图进行自引导滤波和 L_p 范式的同时,设计了一个权重矩阵来抑制反射图的噪声并保留纹理.遗憾的是这些处理仅在HSV(hue, saturation, value)颜色模型中的亮度通道上进行,忽视了同样存在于色相和饱和度通道的噪声,导致降噪能力有限.

本研究提出一个在RGB色彩空间中同时处理所有色彩通道的多通道弱光图像增强算法,主要改进如下为:①对所有色彩通道进行Retinex模型分解,完整处理RGB三通道的噪声;②使用序列分解的策略获取照明图,将图像中的噪声尽可能分配给反射图^[17],同时使用分数阶范式约束照明图梯

度,以保持照明图的分区分平滑;③同时使用基于输入图像信息计算出的反射图梯度权重矩阵和针对RGB全通道设计的抑制小梯度、放大其余梯度的反射图梯度正则项,以防止反射图过度平滑并保留更多边缘和纹理细节.

1 经典Retinex模型和变分Retinex模型

根据Retinex理论,图像 I 可分解为照明图分量 L 和反射图分量 R ,即

$$I = L \circ R \quad (1)$$

其中, $\circ$ 为哈达玛积操作符; L 描述图像的光照强度,逐片连续且无纹理; R 为图像中物体的物理特性,包含图像的纹理和细节.Retinex分解可由变分优化模型(2)实现.

$$\arg \min_{L, R} \alpha \|L \circ R - I\|_F^2 + \beta \|\nabla L\|_F^2 + \lambda \|\nabla R\|_F^2 \quad (2)$$

其中, α 、 β 和 λ 为各正则项的权重参数; $\|L \circ R - I\|_F^2$ 为保真项; $\|\cdot\|_F$ 为矩阵的Frobenius范数.为降低乘法运算的复杂度,模型(2)可转换成对数形式来计算^[13],然而这会使正则化因子被隐式加权,因此本研究选择直接处理原始图像.

2 全局Retinex模型

本研究提出的光照增强方法基于Retinex理论,目标是分解出最理想的照明层和反射层分量.输入1幅彩色图像,归一化图像后同时在3个颜色通道上执行算法.估计出的照明层和反射层分量,经伽玛校正后组合为最后的输出图像.图1为GRM总体框架图.

2.1 模型提出

求解反射图和照明图分量的Retinex模型为

$$\arg \min_{L, R} \alpha \|L \circ R - I\|_F^2 + \beta \|\nabla L\|_p^p + \delta \|W \circ (\nabla R - G)\|_F^2 \quad (3)$$

其中, α 、 β 和 δ 为各正则项的权重参数; W 为约束反射图梯度的权重矩阵; G 由输入的梯度矩阵经过一定的处理得到,如小节2.2.2所示.本研究同时使用了水平梯度和垂直梯度,实现完整利用像素点周围信息.模型(3)中, $\|L \circ R - I\|_F^2$ 可确保模型输出接近于输入图像; $\|\cdot\|_p^p$ 为矩阵的分数阶范数, $\|\nabla L\|_p^p$ 约束照明图,使其分段平滑;




图1 GRM 总体框架图

Fig. 1 Overall framework of GRM.

$\|W \circ (\nabla R - G)\|_F^2$ 约束反射图, 实现降噪和保留反射图中边缘和纹理细节的效果.

选择交替方向乘子法 (alternating direction method of multipliers, ADMM) 优化目标模型. 用辅助变量 T 代替 ∇L , 则模型(3)的增广拉格朗日函数可写为

$$\mathcal{L} = \alpha \|L \circ R - I\|_F^2 + \beta \|T\|_p^p + \delta \|W \circ (\nabla R - G)\|_F^2 + \langle \Phi, \nabla L - T \rangle + \frac{\mu}{2} \|\nabla L - T\|_F^2 \quad (4)$$

其中, $\Phi \in \mathbb{R}^{M \times N \times 3}$ 为拉格朗日乘子, M 和 N 分别为输入图像水平和垂直方向上的像素数量; μ 为正惩罚参数; $\langle \cdot, \cdot \rangle$ 表示计算矩阵的内积. 优化模型的极小值即为 $\mathcal{L}$ 的鞍点. $\mathcal{L}$ 中的 5 个变量 L 、 R 、 T 、 Φ 和 μ 可由子问题迭代求解得出.

2.2 子问题求解

2.2.1 求解 W

首先求解反射图分量梯度 ∇R 的 W . 限制 ∇R 有助于模型优化^[18]. W 可分区域检测输入图像的特

征, 保护反射图分量纹理和边缘尽可能清晰, 有效保留暗部纹理细节. W 中每个元素的值都是由函数 f_1 和 f_2 计算得来, 如式(5). 令 $I' = I^{1/\gamma}$, $\gamma = 2.2$, 可得到更明亮的 I' , 来计算更准确的 W .

$$W(x, y) = f_1(I'(x, y))^\omega \times f_2(I'(x, y))^\omega \quad (5)$$

$$f_1(I'(x, y)) = 1 - \min\left(K_1 \left| g_{a, \sigma}((I'(x, y))^2) - [g_{a, \sigma}(I'(x, y))]^2 \right|, 1\right) \quad (6)$$

$$f_2(I'(x, y)) = 1 - \max(P_h(I'(x, y)), P_v(I'(x, y))) \quad (7)$$

其中, (x, y) 为像素坐标; K_1 为放大参数. f_1 的计算基于 $I'(x, y)$ 相邻区域中的局部方差. 为抑制噪声, 应用低通高斯滤波器 $g_{a, \sigma}$ 计算该局部方差, a 为核大小, σ 为标准差. 使用最小值函数可将 f_1 的结果限制在 $[0, 1]$. 平坦区域中的较小方差会导致 f_1 接近 1, 反之较大方差会使 f_1 接近 0. 遵循文献[18]在 HSV 色彩空间中亮度通道上的实验经验, 设置式(5)-(7)中的 $K_1 = 4500$, $a = 5$, $\sigma = 2$, $\omega = 1.25$. f_2 由水平和垂直梯度计算而来. 在计算 f_2 之前, 在梯度图上应用与噪声滤波器相同的高斯核. P_h 和 P_v 分别为 I' 在水平和垂直方向上的梯度, P_h 和 P_v 中取值更大者决定函数 f_2 的结果. 若 $I'(x, y)$ 在任一方向上梯度较大, 则权重往往较低. 其中, $P_h(I'(x, y)) = \min(K_2 |g_{a, \sigma}(\nabla_h I'(x, y))|, 1)$, $P_v(I'(x, y)) = \min(K_2 |g_{a, \sigma}(\nabla_v I'(x, y))|, 1)$, ∇_h 和 ∇_v 分别为 $I'(x, y)$ 在水平和垂直方向上的梯度, K_2 的取值为 220.

2.2.2 求解 G

为抑制反射图平滑区域的梯度并最大化保持边缘, 本研究采用文献[16-17]方法, 调整输入图像的梯度后得到

$$G = \left(1 + \lambda_1 e^{-|\nabla I''/\lambda_2|}\right) \circ \nabla I'' \quad (8)$$

$$\nabla I''(x, y) = \begin{cases} 0, & |\nabla I(x, y)| < \epsilon \\ \nabla I(x, y), & \text{其他} \end{cases} \quad (9)$$

其中, λ_1 控制放大的程度; λ_2 控制不同梯度的放大率; ϵ 为过滤小梯度的阈值, 用来抑制噪声. 本研究中 ϵ 、 λ_1 和 λ_2 分别设为 1、2.5 和 10^[17].

2.2.3 更新 R 的子问题

保留与 R 相关的项, 得到子问题

$$\arg \min_R \alpha \|L^{(\tau)} \circ R - I\|_F^2 + \delta \|W \circ (\nabla R - G)\|_F^2 \quad (10)$$

其中, $L^{(\tau)}$ 为第 τ 次迭代 L 的结果, $L^{(0)}$ 初始化为输入图像 I .

将矩阵 R 、 I 和 G 分别变为向量形式 r 、 i 和 g , 则式(10)变形为

$$\arg \min_r \alpha \|\hat{L}^{(\tau)} r - i\|_2^2 + \delta \|\hat{W}(\nabla r - g)\|_2^2 \quad (11)$$

其中, $\hat{L}$ 和 $\hat{W}$ 分别是 L 和 W 的对角矩阵表示. 令式(11)的一阶导数为0, 得到

$$\alpha \hat{L}^{(\tau)} (\hat{L}^{(\tau)} r - i) + \delta \sum_{d \in \{h, v\}} D_d^T \hat{W} \hat{W} (D_d r - g) = 0 \quad (12)$$

解式(12)得到第 $\tau+1$ 次迭代时 R 的闭合解

$$r^{(\tau+1)} = \left[\alpha \hat{L}^{(\tau)} i + \delta \sum_{d \in \{h, v\}} D_d^T \hat{W} \hat{W} g \right] \left(\alpha \hat{L}^{(\tau)} \hat{L}^{(\tau)} + \delta \sum_{d \in \{h, v\}} D_d^T \hat{W} \hat{W} D_d \right)^{-1} \quad (13)$$

D_h 和 D_v 是由后向差分的离散梯度算子得到的 Toeplitz 矩阵, 维数为 $(M \times N \times 3) \times (M \times N \times 3)$. 由于维数较大, 用预条件共轭梯度法^[19]求解式(13).

2.2.4 更新 L 的子问题

设定目标子问题

$$\arg \min_L \alpha \|L \circ R^{(\tau+1)} - I\|_F^2 + \frac{\mu^{(\tau)}}{2} \left\| \nabla L - T^{(\tau)} + \frac{\Phi^{(\tau)}}{\mu^{(\tau)}} \right\|_F^2 \quad (14)$$

为确保大多数噪声留在反射图中, 应用序列分解^[17]求解上述目标函数. 设定初始值 L_0 , 从式(15)得到 L , 并转换为式(16)的向量形式.

$$\arg \min_L \alpha \|L - L_0\|_F^2 + \frac{\mu^{(\tau)}}{2} \left\| \nabla L - T^{(\tau)} + \frac{\Phi^{(\tau)}}{\mu^{(\tau)}} \right\|_F^2 \quad (15)$$

$$\arg \min_l \alpha \|l - l_0\|_2^2 + \frac{\mu^{(\tau)}}{2} \left\| \nabla l - t^{(\tau)} + \frac{\varphi^{(\tau)}}{\mu^{(\tau)}} \right\|_2^2 \quad (16)$$

其中, l 为 L 的向量形式; l_0 为 L_0 的向量形式; $t^{(\tau)}$ 为 $T^{(\tau)}$ 的向量形式; $\varphi^{(\tau)}$ 为 $\Phi^{(\tau)}$ 的向量形式.

对式(16)取一阶导数, 可得

$$\alpha (l - l_0) + \frac{\mu^{(\tau)}}{2} \sum_{d \in \{h, v\}} D_d^T \left(D_d l - t^{(\tau)} + \frac{\varphi^{(\tau)}}{\mu^{(\tau)}} \right) = 0 \quad (17)$$

$$l^{(\tau+1)} = \left(\alpha E + \frac{\mu^{(\tau)}}{2} \sum_{d \in \{h, v\}} D_d^T D_d \right)^{-1} \left[\alpha l_0 + \frac{\mu^{(\tau)}}{2} \sum_{d \in \{h, v\}} D_d^T \left(t^{(\tau)} - \frac{\varphi^{(\tau)}}{\mu^{(\tau)}} \right) \right] \quad (18)$$

2.2.5 更新 T 的子问题

收集并重新排列所有 T 项, 得到子问题

$$\arg \min_T \beta \|T\|_p^p + \frac{\mu^{(\tau)}}{2} \left\| \nabla L^{(\tau+1)} - T + \frac{\Phi^{(\tau)}}{\mu^{(\tau)}} \right\|_F^2 \quad (19)$$

式(19)可表示为 L_p 拟范数的近端映射, 应用 L_p

收缩算子 $\mathcal{S}_p(\chi, s) = \text{sign}(\chi) \max(|\chi| - s^{2-p}, 0)$ 后, 得到 T 的近似解为

$$T^{(\tau+1)} = \mathcal{S}_p \left(\nabla L^{(\tau+1)} + \frac{\Phi^{(\tau)}}{\mu^{(\tau)}}, \frac{\beta}{\mu^{(\tau)}} \right) \quad (20)$$

其中, χ 为待收缩变量; s 为收缩阈值.

为 P 设置合适值可以实现 L_p 拟范数正则化.

2.2.6 更新 Φ 的策略

$$\Phi^{(\tau+1)} = \Phi^{(\tau)} + \mu^{(\tau)} [\nabla L^{(\tau+1)} - T^{(\tau+1)}] \quad (21)$$

2.2.7 更新 μ 的策略

$$\mu^{(\tau+1)} = \rho \mu^{(\tau)} \quad (22)$$

其中, ρ 为收敛控制参数, $\rho > 1$.

至此一轮迭代结束, 并令 $\tau = \tau + 1$. 设收敛阈值 ε 为 0.001. 当达到收敛条件 $\|(L^{(\tau)} - L^{(\tau-1)}) / (M \times N \times 3)\|_F < \varepsilon$ 或 $\|(R^{(\tau)} - R^{(\tau-1)}) / (M \times N \times 3)\|_F < \varepsilon$, 或最大迭代次数 K 更新停止.

2.3 调整照度

经过多次迭代收敛后得到照明图和反射图分别用 L^* 和 R^* 表示, 采用伽玛校正来增强 L^* , 则有

$$I^* = L^* 1/\gamma \circ R^* \quad (23)$$

算法伪代码请查看论文末尾二维码补充材料.

3 实验

实验在配备 AMD Ryzen 5600X CPU (主频 4.2 GHz) 和 48 Gbyte 内存的个人计算机上使用 Matlab R2023b 进行, 操作系统是 Windows 10.

3.1 实验设置

用于测试的数据集 1 包含 500 幅有对应参考图像的弱光图像 (来自 ADOBE FiveK^[5]); 数据集 2 的 40 幅弱光图像没有对应参考图像 (来自估计照明图

的弱光图像增强算法^[12] (low-light image enhancement via illumination map estimation, LIME)、具有挑战性的弱光图像数据集^[21]、基于二维直方图分层差异表示的对比度增强算法^[22]。分辨率过高的图像使用 Matlab 的调整大小方法按比例缩小, 确保输入的弱光图像的横向和纵向分辨率的最大均不超过 1 000 个像素。实验中式(3)各正则项的平衡权重参数设置为 $\alpha = 1$, $\beta = 3$, $\delta = 0.1$ 。

3.2 对比实验

3.2.1 主观对比

图 2 和图 3 分别源自数据集 1 和 2, 包含了输入图像、真实图像(图 3 中此处为对比算法 DONG^[2]的

结果)、7 种优化模型算法, 以及本文 GRM 的结果。由图 2 和图 3 可见, 部分方法有增强不足导致暗细节丢失, 或增强过度导致颜色失真和泛白化的现象。比如图 2(d), LIME 的结果整体增强过度; 图 2(g) 和 (h) 中, 鲁棒 Retinex 模型 (robust Retinex model, RRM) 和低秩正则化 Retinex 模型 (low-rank regularized retinex model, LR3M) 的结果过于平滑, 丢失了很多纹理细节; 同时 LR3M 增强不足而 RRM 的结果色彩失真。采用 GRM 方法获得的增强图片具有适中的亮度增强和更理想的对比度, 在保留更多细节的同时不会产生光晕和伪影, 在多数情况下都能得到令人满意的结果。



图 2 数据集 1 中弱光图像增强结果的比较

Fig. 2 Comparison of enhanced results for low-light images in the Dataset 1.




图 3 数据集 2 中弱光图像增强结果的比较

Fig. 3 Comparison of enhanced results for low-light images in the Dataset 2.

3.2.2 客观对比

选择广泛使用的峰值信噪比 (peak signal-to-noise ratio, PSNR)、结构相似度 (structural similarity index measure, SSIM)、自然图像质量评估指标^[23] (natural image quality evaluator, NIQE)、基于颜色感知的图像质量指标^[24] (color perception-based picture quality index, CPCQI) 和基于特征集成和回归建模的无参考图像质量评估指标^[25] (no-reference

image quality assessment via feature ensemble and regression modeling, NFERM) 指标进行比较。对数据集 1 中有参考图像的 500 幅图像, 测试了所有指标。对数据集 2 中的 40 幅图像, 由于它们缺少了作为参考的真实图像, 因此仅测试了 NIQE、CPCQI 和 NFERM 三个无需参考的指标, 结果分别见表 1 和表 2, 最优的算法结果加粗, 次优的则是加下划线, 第 3 优的加灰色底纹。从表 1 可见, GRM 模型在

PSNR 和 SSIM 指标上表现最优, 在 CPCQI 上为次优, 说明该模型的结果最接近参考图像, 降噪效果最佳. 在表 2 中, GRM 模型具有最佳的 NIQE 和 NFERM 值, CPCQI 指标在 12 种模型中表现第 3, 可见 GRM 综合最理想. (表中各方法的中英文名称参见文末二维码补充材料)

表1 数据集1的定量比较(500幅图像,有参考)

Table 1 Quantitative comparison of Dataset 1 (500 images with reference).

方法	PSNR	SSIM	NIQE	CPCQI	NFERM
MSRCR ^[9]	13.235	0.611	2.966	0.841	26.929
DONG ^[2]	15.134	0.704	3.754	0.821	27.226
NPE ^[10]	17.176	0.771	2.921	0.860	27.022
MF ^[14]	17.488	0.780	<u>2.949</u>	0.871	26.506
BIMEF ^[3]	17.808	0.719	3.039	0.812	24.901
LIME ^[12]	13.275	0.728	2.967	0.844	32.137
SRIE ^[13]	18.440	0.790	3.017	0.893	<u>25.240</u>
JIEP ^[15]	18.445	0.795	3.039	0.903	26.766
RRM ^[17]	17.637	0.763	3.568	0.755	25.431
LR3M ^[18]	15.846	0.701	3.771	0.764	29.892
PNP ^[19]	<u>18.495</u>	<u>0.798</u>	2.954	0.922	26.530
GRM	19.253	0.805	3.019	<u>0.918</u>	26.783

表2 数据集2的定量比较(40幅图像,无参考)

Table 2 Quantitative comparison of Dataset 2 (40 images with no-reference).

方法	NIQE	CPCQI	NFERM
MSRCR	3.374	0.766	20.033
DONG	3.892	0.966	16.360
NPE	3.194	0.973	16.516
MF	3.411	<u>1.010</u>	15.393
BIMEF	3.207	0.954	16.756
LIME	3.629	0.980	19.762
SRIE	<u>3.187</u>	0.983	17.287
JIEP	3.259	0.994	15.571
RRM	3.597	0.834	20.114
LR3M	3.722	0.788	28.462
PNP	3.336	1.037	<u>13.257</u>
GRM	2.921	0.999	11.849

3.3 模型分析

图4给出了基于数据集1的模型参数敏感性分析. 观测图4(a), 可以确定 β 取值范围应为1~10, 再结合收敛的轮次、主观效果和对照明图和反射图分解的成效, 确定 β 的值为3. 对图4(b)进行同样的观测分析, 确定最后的参数配置为 $\{\alpha, \beta, \delta\} =$




图4 参数敏感性分析

Fig. 4 Analysis of parameter sensitivity.

{1, 3, 0.1}.

图 5 给出了基于一张随机测试图像的模型收敛性分析, 可看到模型于 25 ~ 35 轮迭代之间收敛. 反射图的曲线在第 2 轮时有 1 次凸起, 是与初始化有关的正常现象. 通常情况 35 轮迭代内即可收敛, 因此将最大迭代轮数 K 设为 40.




图 5 模型收敛性分析

Fig. 5 Analysis of model convergence.

结 语

本研究基于 Retinex 理论, 提出一种能有效处理含噪声的弱光图像增强模型 GRM, 从输入图像中分解出反射图和照明图, 并在该过程中消除噪声, 通过伽马校正照明图以增强对比度和亮度, 获得理想结果. 引入收缩映射实现分数阶范数以满足分解出理想照明图的要求. 针对反射图估计, 利用输入图像信息, 采用两种策略保留图像原始边缘和纹理细节, 并有效剔除噪声. 采用交替方向乘法有效求解 GRM, 对于一张分辨率为 512×340 的自然环境弱光图像, GRM 计算耗时约为 22.782 s. 在多个公开测试数据集上的实验结果表明, GRM 不仅在视觉质量方面表现出色, 而且在客观图像质量评估指标得分上, 与目前最先进的方法相比也具有竞争力.

基金项目: 湖南省研究生科研创新资助项目(CX20240692); 中南林业科技大学研究生科研创新基金资助项目(2023CX02091)

作者简介: 吴翰宁(765058609@qq.com), 中南林业科技大学硕士研究生. 研究方向: 计算机视觉.

引 文: 吴翰宁, 易积政, 李潇瑶, 等. 基于全局鲁棒 Retinex 模型的多通道弱光图像增强算法[J]. 深圳大学学报理工版, XXXX, XX(XX): 1-8.

参考文献 / References:

[1] IBRAHIM H, PIK KONG N S. Brightness preserving dynamic histogram equalization for image contrast enhancement [J]. IEEE Transactions on Consumer

Electronics, 2007, 53(4): 1752-1758.

- [2] DONG Xuan, WANG Guan, PANG Yi, et al. Fast efficient algorithm for enhancement of low lighting video [C]// 2011 IEEE International Conference on Multimedia and Expo. Piscataway, NJ, USA: IEEE, 2011: 1-6.
- [3] YING Zhenqiang, LI Ge, GAO Wen. A bio-inspired multi-exposure fusion framework for low-light image enhancement [EB/OL]. (2017-11-02) [访问日期]. <https://arxiv.org/abs/1711.00591>.
- [4] 赵明华, 汶怡春, 都双丽, 等. 基于照度与场景纹理注意力图的低光图像增强[J]. 中国图象图形学报, 2024, 29(4): 862-874.
- ZHAO Minghua, WEN Yichun, DU Shuangli, et al. Low-light image enhancement algorithm based on illumination and scene texture attention map [J]. Journal of Image and Graphics, 2024, 29(4): 862-874. (in Chinese)
- [5] WANG Ruixing, ZHANG Qing, FU C W, et al. Underexposed photo enhancement using deep illumination estimation [C]// IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, USA: IEEE, 2019: 6842-6850.
- [6] CAI Yuanhao, BIAN Hao, LIN Jing, et al. Retinexformer: one-stage Retinex-based transformer for low-light image enhancement [C]// IEEE/CVF International Conference on Computer Vision. Piscataway, USA: IEEE, 2023: 12470-12479.
- [7] 陈彬, 陈克远, 伍世虔. 基于跨域特征融合的低光图像增强算法[J]. 激光与光电子学进展, 2024, 61(24): 340-349.
- CHEN Bin, CHEN Keyuan, WU Shiqian. Low-light image enhancement via cross-domain feature fusion [J]. Laser & Optoelectronics Progress, 2024, 61(24): 340-349. (in Chinese)
- [8] LAND E H. The Retinex theory of color vision [J]. Scientific American, 1977, 237(6): 108-128.
- [9] JOBSON D J, RAHMAN Z, WOODDELL G A. A multi-scale Retinex for bridging the gap between color images and the human observation of scenes [J]. IEEE Transactions on Image Processing, 1997, 6(7): 965-976.
- [10] WANG Shuhang, ZHENG Jin, HU Haimiao, et al. Naturalness preserved enhancement algorithm for non-uniform illumination images [J]. IEEE Transactions on Image Processing, 2013, 22(9): 3538-3548.
- [11] 李潇瑶, 王炼红, 周怡聪, 等. 基于四元数非局部低秩和全变分的图像混合噪声去噪算法[J]. 电子学报, 2023, 51(4): 975-983.

- LI Xiaoyao, WANG Lianhong, ZHOU Yicong, et al. Image mixed denoising using quaternion-based non-local low rank and total variation [J]. *Acta Electronica Sinica*, 2023, 51(4): 975-983. (in Chinese)
- [12] GUO Xiaojie, LI Yu, LING Haibin. LIME: low-light image enhancement via illumination map estimation [J]. *IEEE Transactions on Image Processing*, 2017, 26(2): 982-993.
- [13] FU Xueyang, ZENG Delu, HUANG Yue, et al. A weighted variational model for simultaneous reflectance and illumination estimation [C]// *IEEE Conference on Computer Vision and Pattern Recognition*. Piscataway, USA: IEEE, 2016: 2782-2790.
- [14] FU Xueyang, ZENG Delu, HUANG Yue, et al. A fusion-based enhancing method for weakly illuminated images [J]. *Signal Processing*, 2016, 129: 82-96.
- [15] CAI Bolun, XU Xianming, GUO Kailing, et al. A joint intrinsic-extrinsic prior model for Retinex [C]// *IEEE International Conference on Computer Vision*. Piscataway, USA: IEEE, 2017: 4020-4029.
- [16] 刘波, 田广粮, 肖斌, 等. 利用自适应光照初始化的弱光图像增强方法[J]. *电子与信息学报*, 2024, 46(2): 643-651.
LIU Bo, TIAN Guangliang, XIAO Bin, et al. Low light image enhancement with adaptive light initialization [J]. *Journal of Electronics & Information Technology*, 2024, 46(2): 643-651. (in Chinese)
- [17] LI Mading, LIU Jiaying, YANG Wenhan, et al. Structure-revealing low-light image enhancement via robust Retinex model [J]. *IEEE Transactions on Image Processing*, 2018, 27(6): 2828-2841.
- [18] REN Xutong, YANG Wenhan, CHENG Wenhua, et al. LR3M: robust low-light enhancement via low-rank regularized Retinex model [J]. *IEEE Transactions on Image Processing*, 2020, 29: 5862-5876.
- [19] LIN Y H, LU Yichang. Low-light enhancement using a plug-and-play Retinex model with shrinkage mapping for illumination estimation [J]. *IEEE Transactions on Image Processing*, 2022, 31: 4897-4908.
- [20] KAASSCHIETER E F. Preconditioned conjugate gradients for solving singular systems [J]. *Journal of Computational and Applied Mathematics*, 1988, 24(1/2): 265-275.
- [21] VONIKAKIS V. Busting Image Enhancement and Tone-Mapping Algorithms: A Collection of the Most Challenging Cases [Online]. 2017. Available: <https://sites.google.com/site/vonikakis/datasets>
- [22] LEE C, LEE C, KIM C S. Contrast enhancement based on layered difference representation of 2D histograms [J]. *IEEE Transactions on Image Processing*, 2013, 22(12): 5372-5384.
- [23] MITTAL A, SOUNDARARAJAN R, BOVIK A C. Making a "completely blind" image quality analyzer [J]. *IEEE Signal Processing Letters*, 2013, 20(3): 209-212.
- [24] GU Ke, TAO Dacheng, QIAO Junfei, et al. Learning a no-reference quality assessment model of enhanced images with big data [J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2018, 29(4): 1301-1313.
- [25] GU Ke, TAO Dacheng, QIAO Junfei, et al. Learning a no-reference quality assessment model of enhanced images with big data [J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2018, 29(4): 1301-1313.

【中文责编：英子；英文责编：XX】